

BIG DATA AND TEXT ANALYSIS

18/06/2025

Nome:	Cognome:
Matricola:	

Parte 1	
Parte 2	
Totale	

Regole:

1. La prova dura 2 ore.
2. Durante la prova è vietato comunicare con gli altri e utilizzare funzionalità per il suggerimento del codice e strumenti come ChatGPT e Gemini.
3. Al termine della prova, lo studente rinomina il notebook con il proprio nome e cognome, lo scarica nel formato `.ipynb` e lo manda via email a **federica.rollo@unimore.it** con oggetto: **BDTA: 18-06-2025**.
4. I risultati saranno pubblicati entro il giorno 23/06/2025.

Parte 0: Il Dataset

Preso da kaggle - <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>, il dataset è scaricabile attraverso il link <http://bit.ly/4n56Sec> e contiene informazioni sui clienti di una compagnia telefonica, indicando se hanno abbandonato il servizio (Churn).

Parte 1: Analisi (10 punti)

1. Quante sono le istanze contenute nel dataset? ____ Il dataset è completo (cioè per ogni istanza tutti i valori di ogni attributo sono sempre correttamente specificati - non esistono "missing values")? ____ Il dataset è bilanciato per quanto riguarda la classe da predire? ____ (punti 1)
2. Verificare se i clienti con contratto a lungo termine (`Contract="Two year"`) hanno in media una spesa mensile (`MonthlyCharges`) inferiore rispetto a quelli con contratti mensili o annuali. (punti 2)
3. Discretizzare `tenure` (anzianità del cliente) in 3 gruppi (bassa, media, alta). Creare una tabella pivot che mostri la percentuale di abbandono (`Churn`) per gruppo di anzianità e tipo di contratto. I clienti con anzianità bassa e contratto mensile hanno una probabilità maggiore di abbandonare? (punti 3)
4. Determinare se l'adozione di almeno un servizio extra (`OnlineSecurity`, `OnlineBackup`, `DeviceProtection`, `TechSupport`, `StreamingTV`, `StreamingMovies`) riduce il tasso di abbandono. (punti 2) Creare una nuova feature che conta il numero di servizi aggiuntivi attivi per cliente e verificare con un grafico se il tasso di abbandono diminuisce all'aumentare del numero di servizi attivi. (punti 2)

Parte 2: Trasformazione e Predizione (20 punti)

1. Si vuole predire l'abbandono dei clienti (`Churn`). Ricaricare il dataset originale, eliminare eventuali attributi inutili (giustificare la scelta) e istanze che contengono valori nulli, trasformare opportunamente valori categorici e dividere il dataset in 75% train e 25% test, preservando le proporzioni delle classi nella colonna target. Confrontare la predizione ottenuta sia sul dataset train sia sul dataset test dai classificatori `LogisticRegression`, `RandomForestClassifier` e da un dummy classifier a scelta. Effettuare alcune considerazioni sui risultati ottenuti, tenendo in considerazione i valori di accuracy, F1 e della confusion matrix. (punti 4)
2. La predizione di `RandomForestClassifier` è influenzata dal genere? Valutare sui dati di test se la probabilità di abbandono calcolata sulle donne è la stessa per gli uomini (punti 2). Valutare se l'accuratezza di predizione ottenuta negli uomini è la stessa ottenuta nelle donne (punti 2). Eliminare l'attributo `gender` e valutare se l'accuratezza ottenuta negli uomini è la stessa ottenuta nelle donne (punti 1).
3. A partire dal dataset utilizzato al punto 1, trovare i migliori parametri di `max_depth` e `n_estimators` in `RandomForestClassifier`. Come cambia l'F1-score? (punti 2)
4. A partire dal dataset originale, dopo aver applicato un Label Encoder alle feature categoriche, considerare le 5 feature più correlate (positivamente o negativamente) a `Churn` e verificare se la predizione di `RandomForestClassifier` migliora. (punti 3)
5. Creare una pipeline che, a partire dal dataset originale, discretizza `MonthlyCharges` in 5 gruppi, applica `OneHotEncoder` alle variabili categoriche e usa `StandardScaler` sulle variabili numeriche. Applicare il `RandomForestClassifier` con i valori migliori dei parametri analizzati nel punto 3 e confrontare i risultati. (punti 3)
6. Aggiungere alla pipeline del punto 5 la funzione `SelectKBest`. Utilizzare la funzione di `gridSearchCV` per selezionare il `K` migliore e anche i valori migliori dei parametri `max_depth` e `n_estimators` di `RandomForestClassifier` (scegliere a piacere alcuni valori). (punti 3)